

Latenz vs. Zuverlässigkeit: die LLM-Wahl ist der Hebel

Die schnellste Pipeline (Groq) läuft real nur in ~67 % der Fälle durch

