



Befund 1: Cloudflare-Fronting

Kommunikationsmatrix: Provider × ASN (Pakete pro Capture, Single-Slot 2026-05-04)




Groq, Mistral und beide OpenAI-APIs laufen über Cloudflare-Edge Frankfurt.
RTT-Messungen (Layer 1) messen den Edge-Server, nicht das eigentliche Backend.

Befund 2: Zerlegung des Verbindungsaufbaus (TCP + TLS + Protokoll)




*Rev.ai fällt auf: riesige TLS-Phase durch TLS 1.2 (2-RTT statt 1-RTT).
Alle anderen Provider nutzen TLS 1.3 — erklärt Rev.ai's +140 ms Connect-Overhead.*

Zerlegung der STT-Cold-Start-Latenz — Verbindungsphase vs. Server-Processing



Befund 4: LLM — Groq LPU vs. GPU (Generierungszeit)



*Groq (LPU-Hardware): 7 ms Median-Generierungszeit. OpenAI (GPU): 89 ms.
Der Hardware-Unterschied ist direkt messbar — Faktor ~13x.*