

Exposé zur Bachelorarbeit

Bachelorarbeit (B.Sc. Informatik, TU Dresden)

Autor: Anton Rusik · Matrikelnummer 4847595

Erstprüfer: Prof. Dr. Matthias Wählich

Arbeitstitel (Arbeitsstand, noch nicht final entschieden):

Erklärt Netznähe die Latenzunterschiede? Eine drei-schichtige Messstudie zu Cloud-AI-Sprachdiensten (STT, LLM, TTS) aus EU-Sicht

Motivation & Forschungsfrage

Echtzeit-Sprachassistenten verketteten kommerzielle Cloud-Dienste für Spracherkennung (STT), Sprachmodelle (LLM) und Sprachsynthese (TTS) sequenziell. Die Antwortlatenz entscheidet über die Nutzbarkeit, doch ihre Ursachen, also Netzwerk gegenüber Backend-Verarbeitung, werden kaum getrennt gemessen. Öffentliche Latenz-Benchmarks solcher Dienste vermischen beide Anteile typischerweise, während die hier verwendete paket-validierte Schichtentrennung sie überhaupt erst getrennt messbar macht. Die Arbeit liefert eine empirische Latenz- und Verfügbarkeits-Charakterisierung dieses kommerziellen LLM-/AI-Servings, deren schärfsten Befund die LLM-Stufe liefert.

Leitfrage

*In welchem Maße erklären **Netzwerk- und Infrastruktureigenschaften** (RTT, Protokoll, Hosting-Region), verglichen mit der **Backend-Verarbeitung** der Anbieter, die Latenzunterschiede zwischen kommerziellen Cloud-AI-APIs aus EU-Perspektive, und wie sich daraus die sequenzielle Cold-Start-Gesamtlatenz der Voice-Pipeline ergibt?*

Die Frage ist bewusst offen, denn auch der Befund, dass das Netzwerk *weniger* erklärt als das Backend, wäre ein ebenso tragfähiges Ergebnis. Neben der Latenz wird die Verfügbarkeit (Fehlerrate) je Endpunkt als eigene Achse erhoben.

Methodik

Gemessen wird von einem festen Vantage Point (AWS EC2, Frankfurt) gegen neun Endpunkte, also je drei Anbieter pro Stufe: STT (Deepgram, Rev.ai, Azure), LLM (OpenAI, Groq, Mistral) und TTS (Deepgram, OpenAI, Azure). Drei sauber getrennte Messschichten:

- **Layer 1 (Infrastruktur):** DNS, RTT (TCP/ICMP), TLS, Traceroute, ASN → Netznähe zum Host.
- **Layer 2 (Paketebene):** Verkehrsaufzeichnung (tcpdump/PCAP) zur **paketbasierten Validierung des Connect-Timers**. Der in der Anwendung gemessene Wert stimmt mit dem aus den Paketen abgeleiteten auf ~0,1 ms überein. (Die Antwortlatenzen `ttft`/`ttfa` nutzen denselben Messmechanismus, sind aber nicht direkt paket-geeicht.)
- **Layer 3 (API-Latenz):** Cold-Start-Messung, also jede Anfrage über eine frische Verbindung ohne Connection-Pooling, da aus EU-Sicht gerade der Verbindungsaufbau zum Backend der interessante Anteil ist. Erfasst werden atomare Submetriken (TCP-/TLS-/WebSocket-Handshake) sowie Time-to-first-Token/-Audio.

Zielumfang: 7-Tage-Kampagne, 8 Zeitslots pro Tag, $n=100$ je Endpunkt und Slot, interleaved, insgesamt rund 50.000 Einzelmessungen. Vorläufig ausgewertet werden die bislang erhobenen Slots robust mit Bootstrap-Konfidenzintervallen, wobei die Aggregation (Median der Slot-Mediane gegenüber gepoolt) noch gegengeprüft wird. Die Latenz wird nur auf erfolgreichen Calls betrachtet, die Verfügbarkeit getrennt als eigene Achse ausgewiesen.

Zentrales Ergebnis (Zwischenstand)

Die drei LLM-Anbieter terminieren **alle am selben Cloudflare-Edge in Frankfurt**: je Anbieter beide DNS-rotierten Edge-IPs als AS13335 bei ~1 ms TCP-RTT gemessen und per ASN-Lookup bestätigt (100 % des LLM-Traffics). Trotz nahezu identischer Netzanbindung streut die Antwortlatenz um **rund das Sechseinhalbfache (~6,5×)**, wobei die geografische Ordnung sogar invertiert ist: Ein EU-gehosteter Dienst ist langsamer als ein US-Dienst.

Die belastbare Aussage ist daher negativ: **Die Netznähe erklärt die Spreizung nicht**. Die Differenz liegt also nicht in der EU-Edge-Nähe, sondern im Backend und Serving, etwa in der Inferenz-Hardware (zum Beispiel Groqs LPU gegenüber GPU-Serving), der Modellgröße und dem Serving-Stack. Diese positive Lesart trägt einen unvermeidbaren Modellgrößen-Confound, denn das schnellste Modell ist zugleich das kleinste auf Spezialhardware, und wird transparent diskutiert. Die negative Kernaussage bleibt davon unberührt, da bereits die invertierte Geografie-Ordnung Netznähe als Erklärung ausschließt. Der Befund ist zudem vom einzelnen Vantage Point unabhängig, weil er bei *konstanter* Netzdistanz (gleicher Edge, ~1 ms für alle drei LLM) auftritt.

Beitrag, Abgrenzung, Stand

- **Kernbefund:** empirischer Nachweis, dass Netznähe die Latenzspreizung nicht erklärt, am stärksten an LLMs mit identischem Edge. STT trägt zur Engine-These bewusst nicht bei, da es auf der fairen Metrik Engine und Geografie nicht scharf trennt, und dient als methodischer Kontrast- und Verfügbarkeitsfall.
- **Methodischer Beitrag:** eine reproduzierbare, mehrfach auditierte Drei-Schichten-Methodik samt paket-validierter Edge-Grenze für Performance-Aussagen über kommerzielle Blackbox-AI-Dienste.
- **Methoden-Baustein:** eine ping-basierte Heuristik zur Klassifikation der Connect-Zusammensetzung. Aus den Phasen wird die sequenzielle Cold-Start-Gesamtlatenz der Pipeline zusammengesetzt.
- **Out of Scope:** Transkriptions- und Ausgabequalität (gemessen werden nur Latenz und Verfügbarkeit) sowie der einzelne Vantage Point (Frankfurt). Die RTT- und Edge-Zahlen sind FRA-spezifisch, der Backend-Kernbefund ist davon unberührt.
- **Stand:** Die Messinfrastruktur steht und ist mehrfach auditiert. Die Kampagne läuft noch, danach folgen Auswertung, Statistik und schriftliche Ausarbeitung (geplante Fertigstellung voraussichtlich im August 2026).